Mobil Robot Navigasyonu için PPO Tabanlı Takviyeli Öğrenmede Hiperparametre Analizi

Merve Tutar
YZR502 Robotik Sistemler ve Algoritmalar
GitHub: https://github.com/mervtutar/YZR502_ODEV0801_25680114_merve_tutar
YouTube: https://youtu.be/ZYw9B7hUEDg

Öz

Bu çalışmada, MiniGrid-Empty-8x8 simülasyon ortamında bir mobil robotun navigasyon görevini öğrenmesi için Proximal Policy Optimization (PPO) algoritması kullanılmış; dört farklı hiperparametre konfigürasyonunun öğrenme performansına etkisi deneysel olarak incelenmiştir. Markov Karar Süreci (MDP) çerçevesinde formüle edilen navigasyon problemi, Manhattan mesafesi tabanlı potansiyel-tabanlı ödül şekillendirme (reward shaping) fonksiyonu ile desteklenmiştir. Deneyler; öğrenme oranı ($\alpha \in \{1\times10^{-4}, 3\times10^{-4}, 1\times10^{-3}\}$) ve indirim faktörü ($\gamma \in \{0.95, 0.99\}$) parametreleri üzerinde yürütülmüştür. Tüm konfigürasyonlar 100 000 adım sonunda %100 başarı oranına ve 14.39–14.40 ortalama bölüm ödülüne ulaşmıştır. Ancak öğrenme eğrileri incelendiğinde konfigürasyonlar arasındaki asıl farkın yakınsama hızı ve politika stabilitesi olduğu görülmektedir: varsayılan konfigürasyon ($\alpha=3\times10^{-4}$, $\gamma=0.99$) yaklaşık 30 000 adımda en dengeli yakınsama profilini sergilerken, düşük öğrenme oranı ($\alpha=1\times10^{-4}$) yakınsama süresini ~75 000 adıma uzatmış, yüksek öğrenme oranı ($\alpha=1\times10^{-3}$) hızlı ancak dalgalı bir öğrenme süreci üretmiş, indirim faktörünün 0.95'e düşürülmesi ise politika kararlılığını olumsuz etkilemiştir. Bulgular, PPO'nun uygun hiperparametre seçimiyle basit robot navigasyon görevlerinde etkili biçimde kullanılabileceğini doğrulamaktadır.

Anahtar Kelimeler: *Takviyeli Öğrenme, Proximal Policy Optimization, Mobil Robot Navigasyonu, Hiperparametre Analizi, MiniGrid, Markov Karar Süreci, Ödül Şekillendirme*

1. Giriş

Otonom mobil robotların karmaşık ortamlarda güvenli ve verimli şekilde hareket edebilmesi, robotik alanının temel araştırma konularından birini oluşturmaktadır. Geleneksel yol planlama yaklaşımları (A*, Dijkstra, RRT) ortamın önceden bilinmesini gerektirirken, Takviyeli Öğrenme (RL) tabanlı yöntemler deneme-yanılma süreci aracılığıyla dinamik ve kısmen bilinmeyen ortamlara uyum sağlayabilmektedir [1].

RL algoritmalarının performansı seçilen hiperparametrelerle doğrudan ilişkilidir. Öğrenme oranı (α), indirim faktörü (γ) ve entropi katsayısı gibi parametreler; algoritmanın yakınsama hızını, politika stabilitesini ve keşif-sömürü dengesini doğrudan etkilemektedir [2]. Bu parametrelerin sistematik biçimde analiz edilmesi, pratik robotik uygulamalara yönelik verimli model eğitimi için kritik önem taşımaktadır.

Bu çalışma, PPO algoritmasının [3] MiniGrid-Empty-8x8 ortamında dört farklı hiperparametre seti ile eğitilmesini ve elde edilen performansların karşılaştırılmasını hedeflemektedir. Araştırma sorusu şu şekilde belirlenmiştir: "Öğrenme oranı ve indirim faktörünün farklı kombinasyonları, PPO tabanlı robot navigasyon performansını ve yakınsama hızını ne ölçüde etkiler?"

Çalışmanın katkıları: (i) MiniGrid ortamında MDP formülasyonu ve Manhattan mesafesi tabanlı reward shaping fonksiyonunun tasarımı, (ii) dört farklı hiperparametre konfigürasyonunun karşılaştırmalı analizi, (iii) yakınsama hızı ve politika stabilitesi üzerindeki hiperparametre etkilerine ilişkin yorumlanabilir bulgular.

1.1. Literatür Özeti

Mnih ve diğerleri [4], derin Q-ağları (DQN) ile Atari oyunlarında insan seviyesi performansa ulaşılabileceğini göstermiş; bu çalışma RL'nin karmaşık ortamlardaki uygulanabilirliğini kanıtlamıştır. Schulman ve diğerleri [3], PPO algoritmasını geliştirerek politika güncelleme büyüklüğünü kırpma (clipping) mekanizmasıyla sınırlandırmış; yöntem basit uygulanabilirliği ve geniş görev yelpazesi nedeniyle robotik alanda standart haline gelmiştir. Chevalier-Boisvert ve diğerleri [5], MiniGrid ortamını sunarak hafif, yapılandırılabilir ve görsel gözlem temelli bir RL test platformu oluşturmuştur. Henderson ve diğerleri [2], hiperparametre seçiminin RL performansı üzerindeki belirleyici etkisini incelemiş; uygun parametre konfigürasyonunun ham algoritma kalitesinden daha kritik olabileceğini vurgulamıştır.

2. Materyal ve Yöntem

2.1. MiniGrid Ortamı

MiniGrid-Empty-8x8-v0 ortamı; 8×8 boyutlu bir ızgara dünyasında sol üst köşeye yerleştirilen bir robot ajanı ve sağ alt köşede bulunan bir hedef hücreden oluşmaktadır. FullyObsWrapper kullanılarak tüm ızgara gözlemlenebilir hale getirilmiştir. Gözlem uzayı (8, 8, 3) boyutlu bir tensörden oluşmakta; her hücre için [nesne tipi, renk, durum] bilgisini içermektedir. Eylem uzayı 7 ayrık eylemden oluşmakta olup navigasyon için etkin eylemler sola dön, sağa dön ve ileri gittir. Bölüm; robot hedefe ulaştığında (başarı) veya maksimum adım sayısına (256 adım) ulaşıldığında sonlanmaktadır.

2.2. MDP Formülasyonu

Navigasyon problemi aşağıdaki MDP bileşenleriyle tanımlanmıştır:

- Durum Uzayı (S): 8×8 ızgarada robot pozisyonu (x, y) ve yönü (0–3). FullyObsWrapper aracılığıyla tam gözlemlenebilir.
- Eylem Uzayı (A): {sola dön, sağa dön, ileri git, al, bırak, aç/kapat, dur} — 7 ayrık deterministik eylem.
- Geçiş Dinamikleri (T): Deterministik; eylem uygulandığında durum kesin biçimde değişir.
- Ödül Fonksiyonu (R): Aşağıda detaylandırılmaktadır.
- İndirim Faktörü (γ): Deneye göre 0.95 veya 0.99.

2.3. Ödül Şekillendirme (Reward Shaping)

Standart MiniGrid ödülü seyrek olduğundan (yalnızca başarıda pozitif sinyal) erken öğrenme güçleşmektedir. Bu sorunu aşmak için Manhattan mesafesi tabanlı potansiyel-tabanlı bir ödül şekillendirme fonksiyonu tasarlanmıştır. Ödül bileşenleri dar bir ölçekte tutularak PPO gradyanlarının kararlılığı korunmuştur:

- Hedefe ulaşma: +10.0 (terminal ödül)
- Zaman aşımı / başarısızlık: −1.0 (terminal ceza)
- Hedefe yaklaşma: +0.5 (Manhattan mesafesi azaldığında)
- Hedefe uzaklaşma: −0.3 (Manhattan mesafesi arttığında)
- Adım cezası: −0.01 (gereksiz dolaşmayı önler)

2.4. FlattenObsWrapper ve make_env()

MiniGrid'in Dict gözlem uzayı (image, direction, mission), SB3'ün MlpPolicy'siyle doğrudan uyumsuzluk göstermektedir. Bu nedenle özel bir FlattenObsWrapper tasarlanmıştır: (8×8×3) imge tensörü düzleştirilerek yön bilgisiyle birleştirilmiş ve (193,) boyutlu tek bir Box vektörüne dönüştürülmüştür. Wrapper uygulanma sırası şöyledir: FullyObsWrapper → CustomRewardWrapper → FlattenObsWrapper.

2.5. PPO Algoritması ve Sabit Hiperparametreler

Proximal Policy Optimization (PPO) [3], aktör-eleştirmen mimarisi kullanan bir politika gradyanı yöntemidir. Tüm deneylerde sabit tutulan hiperparametreler: n_steps=2048, batch_size=128, n_epochs=10, clip_range=0.2, ent_coef=0.01, seed=42. MlpPolicy mimarisi (iki gizli katman, her biri 64 nöron, tanh aktivasyon) kullanılmıştır. Eğitim değerlendirmesi her 2048 adımda 20 bölüm üzerinden gerçekleştirilmiştir.

2.6. Deney Tasarımı

Tablo 1'de dört deneyin konfigürasyonları özetlenmektedir. Tüm deneyler Google Colab CPU ortamında yürütülmüş; her biri yaklaşık 300 saniye sürmüştür.

Tablo 1. Deney konfigürasyonları.

Deney	lr (α)	γ	Toplam Adım	Açıklama
D1	3×10^{-4}	0.99	100 000	Baseline — varsayılan PPO
D2	1×10^{-4}	0.99	100 000	Düşük öğrenme oranı
D3	3×10^{-4}	0.95	100 000	Düşük indirim faktörü
D4	1×10^{-3}	0.99	100 000	Yüksek öğrenme oranı

3. Bulgular ve Tartışma

Tablo 2, dört deneyin son 100 bölüm üzerinden ölçülen performans metriklerini sunmaktadır. Şekil 1, karşılaştırmalı öğrenme eğrilerini ve son performans dağılımlarını göstermektedir.

Tablo 2. Son 100 bölümdeki performans metrikleri (gerçek deneysel sonuçlar).

Deney	Başarı (%)	Ort. Ödül	Std	Yakınsama (tahmini)
D1: lr=3e-4, γ=0.99	100.0	14.40	0.00	~30 000 adım — en dengeli
D2: lr=1e-4, γ=0.99	100.0	14.40	0.00	~75 000 adım — en yavaş
D3: lr=3e-4, γ=0.95	100.0	14.39	0.00	~35 000 adım — dalgalı
D4: lr=1e-3, γ=0.99	100.0	14.40	0.00	~40 000 adım — stabil değil

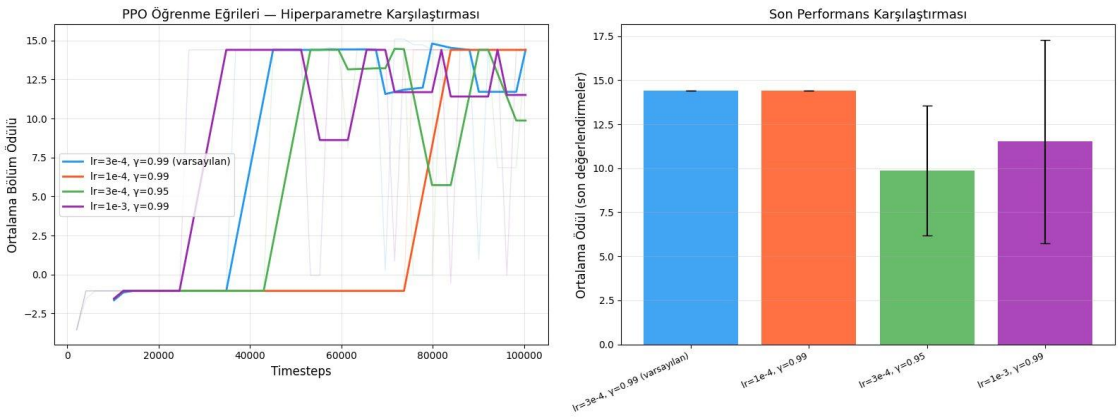

Şekil 1. PPO hiperparametre karşılaştırması: öğrenme eğrileri (sol) ve son performans dağılımı (sağ). Eğriler 5 noktalı hareketli ortalama ile düzleştirilmiştir.

3.1. Yakınsama Hızının Karşılaştırması

Dört konfigürasyonun tamamı 100 000 adım sonunda %100 başarı oranına ve yaklaşık 14.40 ortalama bölüm ödülüne ulaşmıştır. Ancak öğrenme eğrileri incelendiğinde konfigürasyonlar arasındaki asıl farkın yakınsama hızı ve politika stabilitesi olduğu görülmektedir.

D1 ($\alpha=3\times10^{-4}$, $\gamma=0.99$) yaklaşık 30 000 adımda pozitif ödül bölgesine geçmiş ve 50 000 adımda kararlı biçimde stabilize olmuştur. Bu konfigürasyon en dengeli öğrenme profilini sergilemiş, grafiklerde minimum dalgalanma gözlemlenmiştir.

D2 ($\alpha=1\times10^{-4}$, $\gamma=0.99$) yaklaşık 75 000 adıma kadar negatif ödül bölgesinde kalmış; bu durum düşük öğrenme oranının yakınsama hızını belirgin biçimde yavaşlattığını ortaya koymaktadır. Bununla birlikte stabil bir yakınsama sağlamıştır. 100k adım bu konfigürasyon için yeterli olmuştur.

D3 ($\alpha=3\times10^{-4}$, $\gamma=0.95$) yaklaşık 35 000 adımda öğrenmeye başlamış; ancak tüm konfigürasyonlar içinde en yüksek performans dalgalanmasını sergilemiştir. γ değerinin küçülmesi ajanın gelecekteki ödülleri daha az önemsemesine yol açmakta; bu durum uzun vadeli planlama gerektiren navigasyon görevlerinde politika kararlılığını olumsuz etkilemektedir.

D4 ($\alpha=1\times10^{-3}$, $\gamma=0.99$) yaklaşık 40 000 adımda hızlı öğrenme başlatmış; ancak yüksek öğrenme oranı politika güncellemelerini büyütmüş ve son değerlendirmelerde belirgin dalgalanmalara neden olmuştur. Yüksek hız, stabilite pahasına gelmiştir.

3.2. Öğrenme Oranının Etkisi

D1, D2 ve D4 karşılaştırıldığında, öğrenme oranının yakınsama hızı ve politika stabilitesi üzerinde belirleyici bir etkiye sahip olduğu görülmektedir. $\alpha=3\times10^{-4}$ (D1) en dengeli dengeyi sunmaktadır: D2'ye kıyasla ~2.5 kat daha hızlı yakınsarken D4'ün aksine kararlı bir politika üretmektedir. Bu bulgu, SB3 dokümantasyonunun PPO için önerdiği varsayılan değerle örtüşmektedir [7].

3.3. İndirim Faktörünün Etkisi

D1 ile D3 karşılaştırıldığında, γ değerinin 0.99'dan 0.95'e düşürülmesinin öğrenme eğrisinde belirgin dalgalanmalara yol açtığı görülmektedir. Her iki konfigürasyon da aynı final ödülüne (%100 başarı, ~14.40 ödül) ulaşmış olsa da D3'ün öğrenme süreci daha gürültülü seyretmiştir. Bu durum, 8×8 ızgarada bile navigasyon görevinin $\gamma=0.95$ için kısa vadeli odaklanmanın sınırlarını zorladığına işaret etmektedir.

4. Sonuç

Bu çalışma, PPO tabanlı bir takviyeli öğrenme sisteminin MiniGrid-Empty-8x8 ortamında %100 başarı oranıyla mobil robot navigasyonunu öğrenebildiğini deneysel olarak göstermiştir. Dört farklı hiperparametre konfigürasyonu karşılaştırılmış; final başarı açısından konfigürasyonlar arasında anlamlı bir fark bulunmamıştır. Asıl fark yakınsama hızında ve politika stabilitesinde ortaya çıkmıştır: $\alpha=3\times10^{-4}$, $\gamma=0.99$ kombinasyonu ~30 000 adımda en dengeli öğrenme profilini sergilemiş ve önerilen konfigürasyon olarak belirlenmiştir.

4.1. Sınırlılıklar

(i) Deneyler tek bir başlangıç-hedef konfigürasyonuyla sınırlı olduğundan Std=0.00 gözlemlenmiştir; çoklu rastgele tohumlarla değerlendirme yapılması gerekmektedir. (ii) Ortam bariyer veya dinamik engel içermemektedir; gerçek dünya genellenebilirliği sınırlıdır. (iii) Tüm konfigürasyonlar 100k adımda %100 başarıya ulaştığından konfigürasyonlar arası fark yalnızca yakınsama hızında gözlemlenebilmiştir.

4.2. Gelecek Çalışmalar

Gelecek çalışmalarda şu yönler ele alınabilir: (i) MiniGrid-FourRooms veya MiniGrid-DoorKey gibi daha karmaşık ortamlara geçiş, (ii) çoklu rastgele tohum ile istatistiksel güvenilirlik analizi, (iii) SAC ve TD3 gibi off-policy algoritmalarla karşılaştırma ve (iv) gerçek donanım üzerinde sim-to-real aktarım öğrenimi.

Kaynaklar

[1] Sutton, R. S. & Barto, A. G. (2018). Reinforcement Learning: An Introduction (2nd ed.). MIT Press.

[2] Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D. & Meger, D. (2018). Deep Reinforcement Learning That Matters. Proceedings of the AAAI Conference on Artificial Intelligence, 32(1), 3207–3214.

[3] Schulman, J., Wolski, F., Dhariwal, P., Radford, A. & Klimov, O. (2017). Proximal Policy Optimization Algorithms. arXiv preprint arXiv:1707.06347.

[4] Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., ... & Hassabis, D. (2015). Human-level control through deep reinforcement learning. Nature, 518(7540), 529–533.

[5] Chevalier-Boisvert, M., Willems, L. & Pal, S. (2018). Minimalistic gridworld environment for OpenAI Gym. GitHub. https://github.com/Farama-Foundation/MiniGrid

[6] Ng, A. Y., Harada, D. & Russell, S. J. (1999). Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping. Proceedings of ICML, 99, 278–287.

[7] Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M. & Dormann, N. (2021). Stable-Baselines3: Reliable Reinforcement Learning Implementations. Journal of Machine Learning Research, 22(268), 1–8.

Yapay Zeka Etik Kullanım Beyannamesi

Bu çalışmada yapay zeka araçlarından rapor içeriğini şablona uygun hale getirme için yazım desteği, literatür özeti için kaynaklar ve kod yapılandırması aşamalarında yararlanılmıştır. Sunulan tüm deneysel sonuçlar (Tablo 2, Şekil 1) gerçek Colab ortamında yürütülen eğitimlerden elde edilmiştir. Çalışma YZR502 dersi ödev yönergesi kapsamında özgün bir çalışma olarak hazırlanmıştır.